

BIG DATA

HUE



EDUARD LARA



1. INTRODUCCION

- HUE es un producto open source aunque está bajo el paraguas de Cloudera, una las distribuciones de Hadoop
- Es un entorno grafico que permite trabajar de manera mucho más amigable con un entorno Hadoop, con distintas características:
- Tiene una serie de editores que nos permiten trabajar con bases de datos Hive, Impala, etc
- Dispone de una especie de editor donde se pueden crear scripts y comandos sin tener que hacerlos desde el modo en línea.
- Tiene un dashboard que permite cargar determinada información y a partir de ahí sacar gráficos y otra serie de características
- ❖ Tiene un planificador con el cual podemos lanzar determinados trabajos a través de uno de esos productos que se llama Oozie dentro de hadoop big data y nos permita sobretodo ejecutar trabajos de manera automática y de forma regular
- ❖ También es un navegador de componentes: permite navegar por HDFS o acceder al metastore de Hive para ver las bd, los ficheros



1. INTRODUCCION

	HIVE	HUE	
Inventor / invención	Hive fue lanzado por Apache Software Foundation.	Hue fue lanzado por Cloudera.	
Alcance / Significado	Hive o HiveQL es un lenguaje de consulta analítica utilizado para procesar y recuperar datos de un almacén de datos.	Hue es una interfaz de usuario web que facilita a los usuarios interactuar con el ecosistema de Hadoop.	
Instalación / Configuración	Hive se puede instalar o configurar mediante la interfaz de línea de comandos de un ecosistema de Hadoop.	Hue se puede instalar o configurar solo con un navegador web.	
Functionalidad	Hive utiliza un algoritmo de reducción de mapas para procesar y analizar los datos.	Hue proporciona un editor de interfaz de usuario web para acceder a Hive y otros lenguajes de programación.	
Implementación	Hive se implementa y se accede a él mediante una interfaz de línea de comandos o una interfaz de interfaz de usuario web.	Hue se implementa en un navegador web para acceder a múltiples programas instalados en Cloudera.	
Dependencia	Hive se puede incrustar en varios marcos de Hadoop.	Hue solo está disponible en el Framework Hadoop basado en Cloudera.	



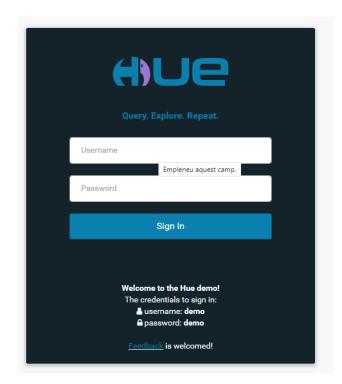
Paso 1. En la página web gethue.com podemos encontrar este producto. Se puede probar antes de instalarlo. El botón Try Hue Now nos lleva a un entorno en la nube ya preparado, que nos permite ver distintas funcionalidades.

Las credenciales para entrar son: usuario demo y password demo.

Query. Explore. Share.

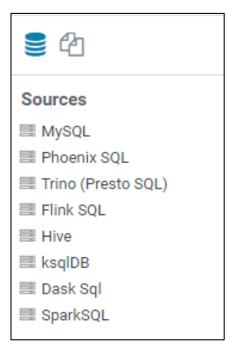
Hue is an open source SQL Assistant for Databases & Data Warehouses

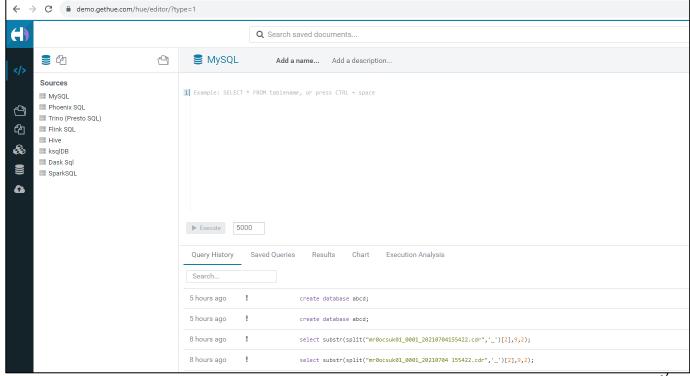
TRY HUE NOW





Paso 2. Aparece un entorno gráfico desde el que nos podemos conectar a diferentes base de datos (Mysql, Hive, SparkSQL, etc) En la parte central tenemos una especie de editor grafico con los comandos que se han ido dando

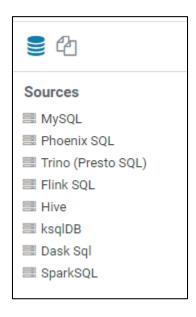


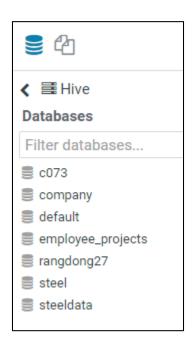


J



- Paso 3. En la parte izquierda podemos acceder a diferentes fuentes de base de datos (Hive, Mysql, SparkSQL, etc). Podemos hacer:
- a) Si seleccionamos Hive podemos ver sus databases.
- b) Si seleccionamos la database default, vemos sus tablas.
- c) Si seleccionamos la tabla employees vemos las columnas que tiene y su estructura



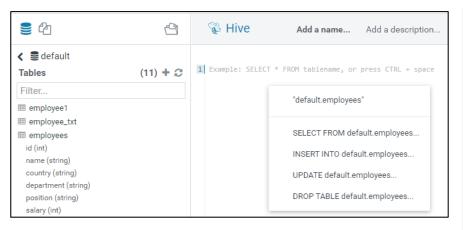


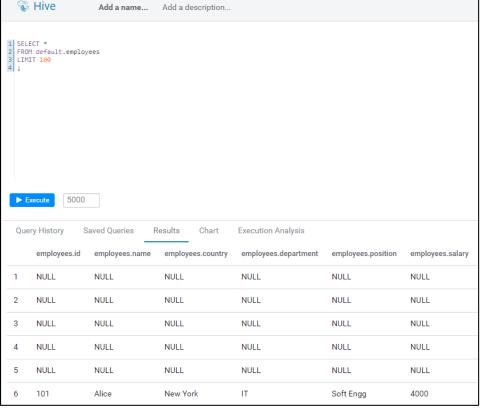
∢ ■ default				
Tables	(11) 🛨 😂			
Filter				
⊞ employee1				
employee_txt				
⊞ employees				
id (int)				
name (string)				
country (string)				
department (string)				
position (string)				
salary (int)				
⊞ my_tbl				
projects				



Paso 4. Podemos poner la consulta de forma automática, arrastrando la tabla al editor y ejecutarla para ver los resultados

Desde aquí es mucho mas fácil trabajar con Hive, todo a nivel grafico, una especie de workbench para Hive



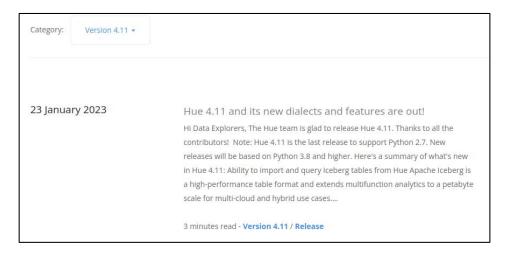


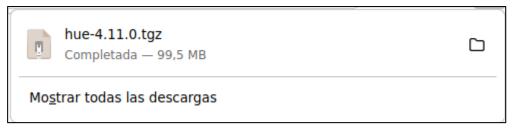


- Es una herramienta que nos permite editar distintos componentes de Hadoop.
- Hue levanta un pequeño servidor web a partir del cual con un navegador puede acceder.
- En Query History están los comandos que se han ido lanzando. Cuando lo instalemos lo veremos con mas detalle
- * Recordar que es un entorno de pruebas con lo cual poco se puede hacer. Solo es para mostrar porque es interesante instalar HUE
- Nos permite trabajar con un entorno Hadoop de una manera mas fácil, grafica y rápida
- Ambari es una herramienta todo terreno que también tiene este tipo de componentes
- HUE es una buena alternativa para los que no vayan a utilizar Ambari o Cloudera, puesto que permite trabajar en entornos Hadoop de una manera mucho más sencilla que la que podemos hacer con líneas de comandos



Paso 1. Descargaremos la versión 4.11 de Hue. Vamos al menú Blog y en AllCategories seleccionamos versión 4.11. Hacemos click en el boton Read Article. Al final de la pagina tenemos las diferentes formas de instalación de Hue. Descargamos la versión tarball









Paso 2. En Downloads descomprimimos el fichero tgz tar xvf hue-4.11.0.tgz

```
hadoop@nodo1:~/Downloads$ ls
access log
                                deslizamientos.csv
                                                      motivo pais.csv
                                                                               MyJob.java
apache-hive-3.1.3-bin.tar.gz
                                empleados.txt
                                                      'MyJob$MapClass.class'
                                                                               tabla deslizamientos.txt
                                                      'MyJob$Reduce.class'
cite75 99.txt
                                hadoop-3.2.4.tar.gz
ContarPalabras.java
                                hadoop-3.3.6.tar.gz
                                                      MyJob.class
countries.csv
                                hue-4.11.0.tgz
                                                      MyJob.jar
hadoop@nodo1:~/Downloads$ tar xvf hue-4.11.0.tgz
```

NOTA: En el directorio de descarga hemos descomprimido el fichero pero aquí no hay binarios, sólo el código fuente. Se debe de compilar para generar los binarios y los componentes necesarios para ejecutarlo en nuestro entorno. No hay unos RPM o instaladores directos.

Antes de realizar la instalación, tenemos que preparar nuestro sistema con una serie de librerías necesarias



```
Paso 3. Instalamos una serie de paquete y librerías necesarios
https://tutorialforlinux.com/2022/08/08/step-by-step-hue-
ubuntu-22-04-installation-guide/
sudo apt update -y
sudo apt install ant gcc g++
sudo apt install libkrb5-dev *libmysqlclient-dev
sudo apt install libssl-dev libsasl2-dev
sudo apt install libsasl2-modules-gssapi-mit
sudo apt install libsglite3-dev libtidy*dev libxml2-dev libxslt-dev
sudo apt install maven libldap2-dev python2-dev
sudo apt install python-setuptools git
pip install --upgrade pip
```



Paso 4. Compilaremos e instalaremos hue. Dentro del directorio hue pondremos el comando PREFIX= y el sitio donde lo queremos instalar. Es un comando típico de Linux para compilar programas Open Source sudo PREFIX=/opt/hadoop make install

Le indicamos que construya todos los componentes. Dejará el resultado en /opt/hadoop, donde generará un directorio llamado hue, con los binarios y todo lo necesario para empezar a trabajar.

```
Post-processed 'dashboard/css/search mobile.css' as 'dashboard/css/search mobile.d3cce15268e8.css'
Post-processed 'oozie/css/workflow.css' as 'oozie/css/workflow.5bf771c653dc.css'
Post-processed 'debug toolbar/css/toolbar.css' as 'debug toolbar/css/toolbar.b35523ea26ab.css'
Post-processed 'rest framework/css/default.css' as 'rest framework/css/default.8d5591a6aabc.css'
Post-processed 'oozie/css/coordinator-editor.css' as 'oozie/css/coordinator-editor.a3cd65079101.css'
Post-processed 'desktop/css/bootstrap-daterangepicker.css' as 'desktop/css/bootstrap-daterangepicker.3b11
8749763b.css'
Post-processed 'desktop/css/jqCron.css' as 'desktop/css/jqCron.ad6fb9a1edc5.css'
Post-processed 'pig/css/pig.css' as 'pig/css/pig.971ef685eb43.css'
Post-processed 'oozie/css/workflow-editor.css' as 'oozie/css/workflow-editor.8a0492fbbc38.css'
Post-processed 'desktop/css/bootstrap-spinedit.css' as 'desktop/css/bootstrap-spinedit.983726642cbb.css'
Post-processed 'rest framework/css/font-awesome-4.0.3.css' as 'rest framework/css/font-awesome-4.0.3.clel
ea213abf.css'
133 static files copied to '/usr/local/hue/build/static', 1145 unmodified, 168 post-processed.
make[1]: Leaving directory '/usr/local/hue'
hadoop@nodo1:~/Downloads/hue-4.10.0$ sudo EXPORT=/opt/hadoop make install
```



Paso 5. Como hemos ejecutado PREFIX con sudo, la carpeta /opt/hadoop/hue pertenece a root. Debemos cambiar el usuario y el grupo a hadoop → sudo chown -R hadoop:hadoop /opt/hadoop/hue

```
hadoop@nodo1:/opt/hadoop$ ls -l
total 216
drwxr-xr-x 2 hadoop hadoop
                             4096 jul 12 2022 bin
drwxr-xr-x 3 hadoop hadoop
                             4096 jul 12 2022 etc
                             4096 mar 18 16:44 hive
drwxrwxr-x 11 hadoop hadoop
drwxr-xr-x 9 root root
                             4096 mar 26 03:47 hue
drwxr-xr-x 2 hadoop hadoop
                            4096 jul 12 2022 include
drwxr-xr-x 3 hadoop hadoop
                             4096 jul 12 2022 lib
drwxr-xr-x 4 hadoop hadoop 4096 jul 12 2022 libexec
-rw-rw-r-- 1 hadoop hadoop 150571 jul 12 2022 LICENSE.txt
                            4096 mar 22 21:02 logs
drwxrwxr-x 3 hadoop hadoop
-rw-rw-r-- 1 hadoop hadoop 21932 jul 12 2022 NOTICE.txt
-rw-rw-r-- 1 hadoop hadoop 1397 feb 23 19:21 README.txt
drwxr-xr-x 3 hadoop hadoop
                             4096 jul 12 2022 sbin
drwxr-xr-x 4 hadoop hadoop
                             4096 jul 12 2022 share
hadoop@nodo1:/opt/hadoop$ sudo chown -r hadoop:hadoop hue
[sudo] password for hadoop:
chown: invalid option -- 'r'
Try 'chown --help' for more information.
1 hadoop@nodo1:/opt/hadoop$ sudo chown -R hadoop:hadoop hue
hadoop@nodo1:/opt/hadoop$ ls -l
total 216
drwxr-xr-x 2 hadoop hadoop
                             4096 jul 12 2022 bin
drwxr-xr-x 3 hadoop hadoop
                             4096 jul 12 2022 etc
drwxrwxr-x 11 hadoop hadoop
                             4096 mar 18 16:44 hive
drwxr-xr-x 9 hadoop hadoop
                             4096 mar 26 03:47 hue
drwxr-xr-x 2 hadoop hadoop
                             4096 jul 12 2022 include
drwxr-xr-x 3 hadoop hadoop
                             4096 jul 12 2022 lib
drwxr-xr-x 4 hadoop hadoop
                             4096 jul 12 2022 libexec
-rw-rw-r-- 1 hadoop hadoop 150571 jul 12 2022 LICENSE.txt
drwxrwxr-x 3 hadoop hadoop
                             4096 mar 22 21:02 logs
-rw-rw-r-- 1 hadoop hadoop 21932 jul 12 2022 NOTICE.txt
-rw-rw-r-- 1 hadoop hadoop
                             1397 feb 23 19:21 README.txt
drwxr-xr-x 3 hadoop hadoop
                             4096 jul 12 2022 sbin
drwxr-xr-x 4 hadoop hadoop
                             4096 jul 12 2022 share
hadoop@nodo1:/opt/hadoop$
```



Paso 1. Si todo ha sido correcto, en el directorio /opt/hadoop/hue tenemos una serie de ficheros y directorios. Para que funcione correctamente debemos de configurar el fichero de configuración /opt/hadoop/hue/desktop/conf/hue.ini

```
hadoop@nodo1:/opt/hadoop/hue$ ls -l

total 68
drwxrwxr-x 3 hadoop hadoop 4096 mar 25 20:00 desktop
drwxr-xr-x 3 hadoop hadoop 4096 mar 24 09:47 ext
-rw-r--r-- 1 hadoop hadoop 11349 mar 22 2021 LICENSE.txt
-rw-r--r-- 1 hadoop hadoop 7043 ene 23 08:57 Makefile
-rw-rw-r-- 1 hadoop hadoop 44 mar 25 20:00 Makefile.buildvars
-rw-r--r-- 1 hadoop hadoop 9062 ene 10 12:30 Makefile.sdk
-rw-r--r-- 1 hadoop hadoop 6054 ene 10 12:30 Makefile.vars
-rw-r--r-- 1 hadoop hadoop 2192 ene 23 08:57 Makefile.vars.priv
-rw-r--r-- 1 hadoop hadoop 1445 ene 23 08:57 README
drwxrwxr-x 4 hadoop hadoop 4096 mar 25 20:00 tools
-rw-r--r-- 1 hadoop hadoop 933 ene 19 07:35 VERSION
hadoop@nodo1:/opt/hadoop/hue$
```

```
hadoop@nodo1:/opt/hadoop/hue/desktop/conf$ ls -l
total 88
-rw-r--r-- 1 hadoop hadoop 79806 ene 10 12:30 hue.ini
-rw-r--r-- 1 hadoop hadoop 1843 ago 10 2020 log4j.properties
-rw-r--r-- 1 hadoop hadoop 1873 mar 22 2021 log.conf
hadoop@nodo1:/opt/hadoop/hue/desktop/conf$
```



Paso 2. Editamos el fichero hue.ini con gedit al tener un tamaño bastante considerable. Hue es un producto que nos va a permitir funcionar contra distintos productos y hay que realizar la configuración para cada uno de ellos. Tenemos que configurarlo para 3 productos ya instalados:

- HDFS
- Yarn
- Hive

Según vayamos viendo otros productos (Pig, Hbase, o Impala) iremos ampliando las propiedades de Hue para trabajar con ellos



Paso 3. Primero configuramos la parte de Hadoop. Buscamos la sección Hadoop donde se configuran sus componentes

```
hue.ini
          \oplus
                                                                      \equiv
  Open ▼
                                                                Save
1186 # Settings to configure your Hadoop cluster.
1188
1189 [hadoop]
1190
1191 # Configuration for HDFS NameNode
1193 [[hdfs clusters]]
1194 # HA support by using HttpFs
1195
1196 [[[default]]]
1197 # Enter the filesystem uri
1198 fs defaultfs=hdfs://localhost:8020
1199
1200 # NameNode logical name.
1201 ## logical name=
1202
1203 # Use WebHdfs/HttpFs as the communication mechanism.
1204 # Domain should be the NameNode or HttpFs host.
1205 # Default port is 14000 for HttpFs.
1206 ## webhdfs url=http://localhost:50070/webhdfs/v1
1207
1208 # Change this if your HDFS cluster is Kerberos-secured
1209 ## security enabled=false
1210
1211 # In secure mode (HTTPS), if SSL certificates from YARN Rest APIs
1212 # have to be verified against certificate authority
1213 ## ssl cert ca verify=True
```



Paso 4. En la uri de HDFS pondremos nodo1:9000

```
[[[default]]]
# Enter the filesystem uri
fs_defaultfs=hdfs://localhost:8020
```

```
[[[default]]]
# Enter the filesystem uri
fs_defaultfs=hdfs://nodo1:9000
```

Estos son los valores que se indican en el fichero /opt/hadoop/etc/hadoop/core-site.xml



Paso 5. Una vez hemos tocado la parte HDFS, vamos a buscar la parte del Yarn que se llama yarn_clusters. Aquí dentro, debemos de cambiar la variable resourcemanager_host de localhost a nodo1. Vemos que el valor de resorcemanager_port es correcto (8032), y por lo tanto no lo tocamos.



Paso 6. Vamos a la sección beeswax, que es la parte de Hive. Cambiamos la variable hive_server_host de localhost a nodo1. El puerto no hace falta cambiarlo porque es el 10000.

```
# Settings to configure Beeswax with Hive
[beeswax]
# Host where HiveServer2 is running.
# If Kerberos security is enabled, use fully-qualified domain name (FQDN).
## hive server host=localhost
# Binary thrift port for HiveServer2.
## hive server port=10000
# Http thrift port for HiveServer2.
## hive server http port=10001
# Host where LLAP is running
## llap server host = localhost
# LLAP binary thrift port
## llap server port = 10500
# LLAP HTTP Thrift port
## llap server thrift port = 10501
```



Paso 7. Más abajo está la parte del metastore, Impala. Por cada producto tendríamos que entrar aquí y configurarlo. Si se instala impala, se debe de configurar la parte de Hue para que se pueda conectar al Impala. Guardamos el fichero y salimos

```
# Settings to configure Metastore
[metastore]
# Flag to turn on the new version of the create table wizard.
## enable new create table=true
# Flag to force all metadata calls (e.g. list tables, table or column detail
via HiveServer2 if available instead of Impala.
## force hs2 metadata=false
# Choose whether to show the table ERD component. Default false
## show table erd=false
# Settings to configure Impala
[impala]
# Host of the Impala Server (one of the Impalad)
## server host=localhost
# Port of the Impala Server
## server port=21050
# Endpoint of the Impala Proxy Server, for example: '/endpoint'.
# Note that SERVER PORT will be used when set.
## proxy endpoint=
```



Paso 8. Ahora falta añadir una propiedad importante que tiene HDFS en el fichero hdfs-site.xml llamada dfs.webhdfs.enabled.

Esta propiedad permite acceder a HDFS a través de web. Es un componente de HDFS que permite hacer llamadas a través de http al entorno Web. Puesta a true, habilitamos la parte de web HDFS que es lo que utiliza HUE para conectarse vía web

```
/opt/hadoop/etc/hadoop/hdfs-site.xml
<!-- Put site-specific property overrides in this file. -->
<configuration>
       cproperty>
               <name>dfs.replication</name>
               <value>2</value>
       </property>
       cproperty>
               <name>dfs.namenode.name.dir</name>
               <value>/datos/namenode</value>
       cproperty>
               <name>dfs.datanode.data.dir
               <value>/datos/datanode</value>
       </property>
       cproperty>
               <name>dfs.webhdfs.enabled</name>
               <value>true</value>
       </property>
</configuration>
```



Paso 9. Por ultimo modificaremos el fichero core-site.xml. Activaremos las propiedades hadoop.proxyuser.hue.hosts y hadoop.proxyuser.hue.groups poniéndole asterisco, es decir indicando que cualquier host de cualquier grupo se pueda conectar.

En la vida real seguramente tendremos que ser un poco más finos, pero por ahora necesario poner asterisco

```
GNU nano 6.2
                                    /opt/hadoop/etc/hadoop/core-site.xml
<!-- Put site-specific property overrides in this file. -->
<configuration>
        cproperty>
                <name>fs.defaultFS</name>
                <value>hdfs://nodo1:9000</value>
        </property>
        cproperty>
                <name>hadoop.proxyuser.hue.hosts</name>
                <value>*</value>
        </property>
        cproperty>
                <name>hadoop.proxyuser.hue.groups</name>
                <value>*</value>
        </property>
</configuration>
```



Paso 10. Arrancaremos Hue para ver que funciona. Pero primero por seguridad debemos activar la interficie que hemos desactivado durante la instalación y reiniciar los servicios de yarn y hdfs:

sudo ifconfig enp0s8 down start-dfs.sh

start-yarn.sh

Paso 11. En la carpeta /opt/hadoop/hue/build/env/bin, hay una serie de comandos que Hue utiliza de manera interna. El comando que

nos interesa es el supervisor

hadoop@nodo1:/opt/hadoop/hue/build/env/bin\$ ls					
activate	hue	odfuserfield	python2.7		
activate.csh	instance_events	parquet	python-config		
activate.fish	jws	parse_xsd2.py	route53		
activate_this.py	kill_instance	pasteurize	rst2html4.py		
asadmin	launch_instance	pip	rst2html5.py		
avro	list_instances	pip2	rst2html.py		
bundle_image	lss3	pip2.7	rst2latex.py		
celery	mailodf	pyami_sendmail	rst2man.py		
cfadmin	make_metadata.py	pybabel	rst2odt_prepstyles.py		
cq	mako-render	pydruid	rst2odt.py		
csv2ods	markdown	pygmentize	rst2pseudoxml.py		
cwutil	mdexport.py	pyjwt	rst2s5.py		
django-admin	merge_metadata.py	pyrsa-decrypt	rst2xetex.py		
django-admin.py	mturk	pyrsa-decrypt-bigfile	rst2xml.py		
dynamodb_dump	ndg_httpclient	pyrsa-encrypt	rstpep2html.py		
dynamodb_load	nosetests	pyrsa-encrypt-bigfile	s3put		
easy_install	nosetests-2.7	pyrsa-keygen	sdbadmin		
easy_install-2.7	odf2mht	pyrsa-priv2pub	sqlformat		
elbadmin	odf2xhtml	pyrsa-sign	supervisor		
fetch_file	odf2xml	pyrsa-verify	tabulate		
futurize	odfimgimport	py.test	taskadmin		
glacier	odflint	pytest	wheel		
	odfmeta	python	xml2odf		
gunicorn_paster	odfoutline	python2_			
hadoop@nodo1:/opt/hadoop/hue/build/env/bin\$					



Paso 12. El comando para arrancar Hue es supervisor: supervisor $-d \rightarrow$ en modo daemon, se ejecuta en 2º plano

```
hadoop@nodol:/opt/hadoop/hue/build/env/bin$ ./supervisor -d hadoop@nodol:/opt/hadoop/hue/build/env/bin$
```

Paso 13. Hacemos ps -ef | grep supervisor, si sale el proceso en principio es que está funcionando:

```
hadoop@nodo1:/opt/hadoop/hue/build/env/bin$ ps -ef | grep supervisor
hadoop 1138264 1346 1 06:22 ? 00:00:00 /opt/hadoop/hue/build/env/bin/python2.7 ./supervisor -d
hadoop 1140044 1850 0 06:23 pts/1 00:00:00 grep --color=auto supervisor
hadoop@nodo1:/opt/hadoop/hue/build/env/bin$
```

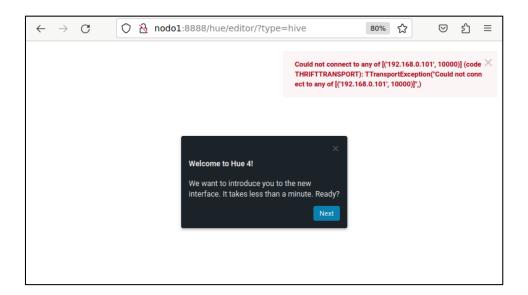
Paso 14. En un navegador ponemos nodo1:8888 (es el valor por defecto de hue). Si todo es correcto deberíamos ver la ventana de conexión





5. PASEO POR HUE

Paso 1. En la ventana de conexión de hue ponemos admin admin y observamos un error





This message indicates that Hive Server is down or HUE Can't reach the server



5. PASEO POR HUE