

---

# **MACHINE LEARNING EN RSTUDIO**

## **ARBOLES DE DECISION**

**EDUARD LARA**

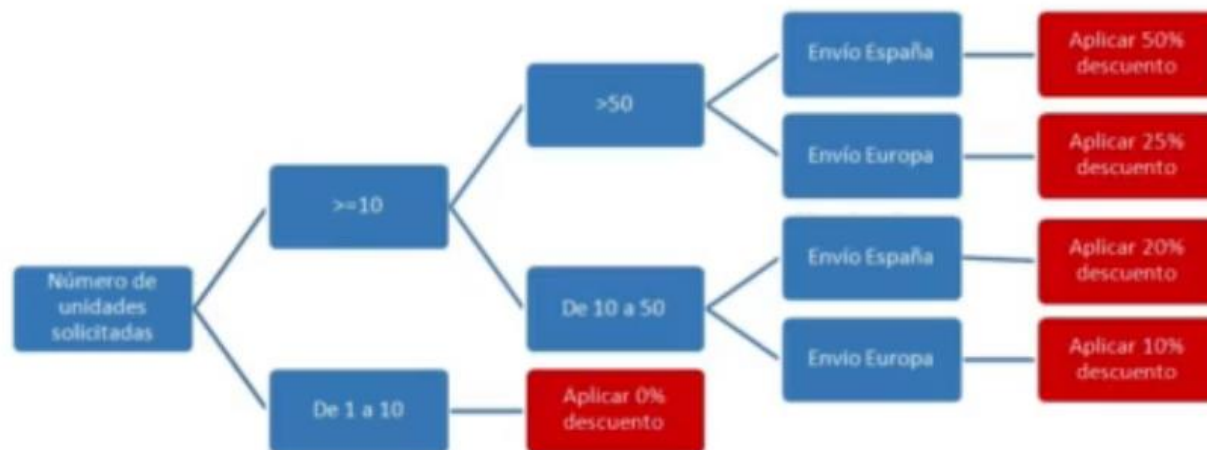
# 1. INDICE

---

1. Introducción árboles de decisión
2. Random Forest
3. Maquina de vectores de soporte
4. Algoritmo de k-medias

# 1. ARBOLES DE DECISION

- Un árbol de decisión es un modelo de predicción utilizado en diferentes ámbitos que van desde la inteligencia artificial hasta la economía
- Dado un conjunto de datos, se fabrica unos diagramas de construcciones lógicas con lo que aparece en la figura, que sirven para representar y categorizar una serie de condiciones que ocurren de forma sucesiva para la resolución de un problema.



# 1. EJEMPLO ARBOLES DE DECISION

---

**Paso 1.** Para ver los árboles de decisión, instalamos primero el paquete `repart`, y lo cargamos en memoria con `library`.

```
> install.packages('repart')
Installing package into 'C:/Users/eduar/AppData/Local/R/win-library/4.3'
(as 'lib' is unspecified)
probando la URL 'https://cran.rstudio.com/bin/windows/contrib/4.3/repart_4.1.23.zip'
Content type 'application/zip' length 710741 bytes (694 KB)
downloaded 694 KB

package 'repart' successfully unpacked and MD5 sums checked

The downloaded binary packages are in
      C:\Users\eduar\AppData\Local\Temp\RtmpSc1MQu\downloaded_packages
>
> library(repart)
>
```

# 1. EJEMPLO ARBOLES DE DECISION

**Paso 2.** Vamos a cargar unos datos mediante el dataset llamado kyphosis. Hacemos un str() de los datos y observamos que contiene 81 observaciones de 4 columnas.

```
> datos = kyphosis
> str(datos)
'data.frame':   81 obs. of  4 variables:
 $ Kyphosis: Factor w/ 2 levels "absent","present": 1 1 2 1 1 1 1 1 1 2 ...
 $ Age      : int   71 158 128 2 1 1 61 37 113 59 ...
 $ Number   : int    3 3 4 5 4 2 2 3 2 6 ...
 $ start    : int    5 14 5 1 15 16 17 16 16 12 ...
> |
```

Data

▶ datos

81 obs. of 4 variables

Kyphosis (enfermedad relacionada con las vertebras) es la columna objetivo que queremos predecir, si está presente o está ausente, en función de la edad (en meses), el número de vértebras y en que vertebra comienza.

# 1. EJEMPLO ARBOLES DE DECISION

---

**Paso 3.** Construimos este árbol de decisión mediante la función `rpart` del paquete que hemos instalado.

```
> arbol = rpart(kyphosis, datos)  
>
```

Indicamos la columna que queremos predecir y le pasamos los datos del dataset completo

# 1. EJEMPLO ARBOLES DE DECISION

**Paso 4.** Imprimiremos este modelo mediante la función `printcp`

```
> printcp(arbol)

Classification tree:
rpart(formula = kyphosis, data = datos)

Variables actually used in tree construction:
[1] Age    Start

Root node error: 17/81 = 0.20988

n= 81

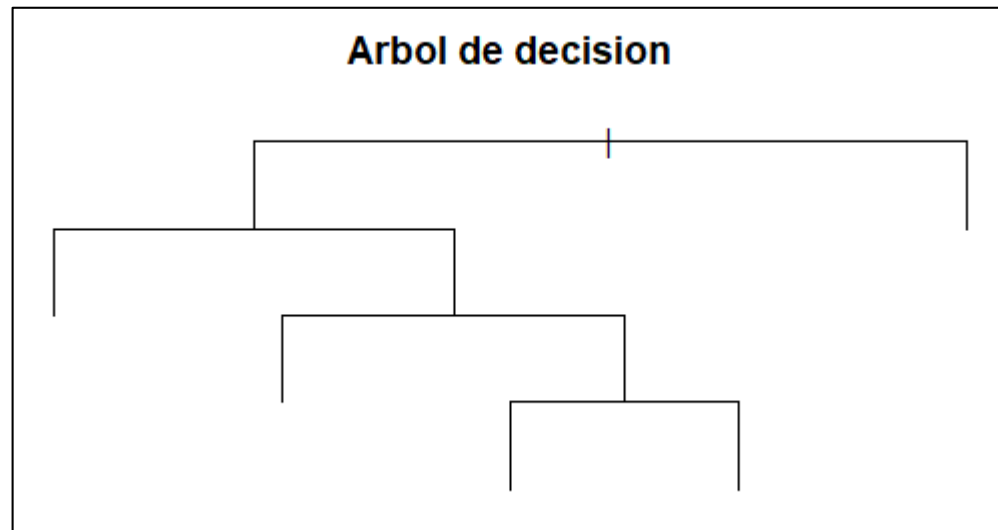
      CP nsplit rel error  xerror   xstd
1 0.176471      0  1.00000 1.0000 0.21559
2 0.019608      1  0.82353 1.1176 0.22433
3 0.010000      4  0.76471 1.1176 0.22433
> |
```

Nos da información sobre el árbol de decisión/clasificación y las tasas de error de cada uno de los datos.

# 1. EJEMPLO ARBOLES DE DECISION

**Paso 5.** Dibujaremos este árbol de decisión mediante plot para que sea mejor. A la derecha pinta el árbol de decisión.

```
> plot(arbol, uniform=TRUE, main='Arbol de decision')  
> |
```



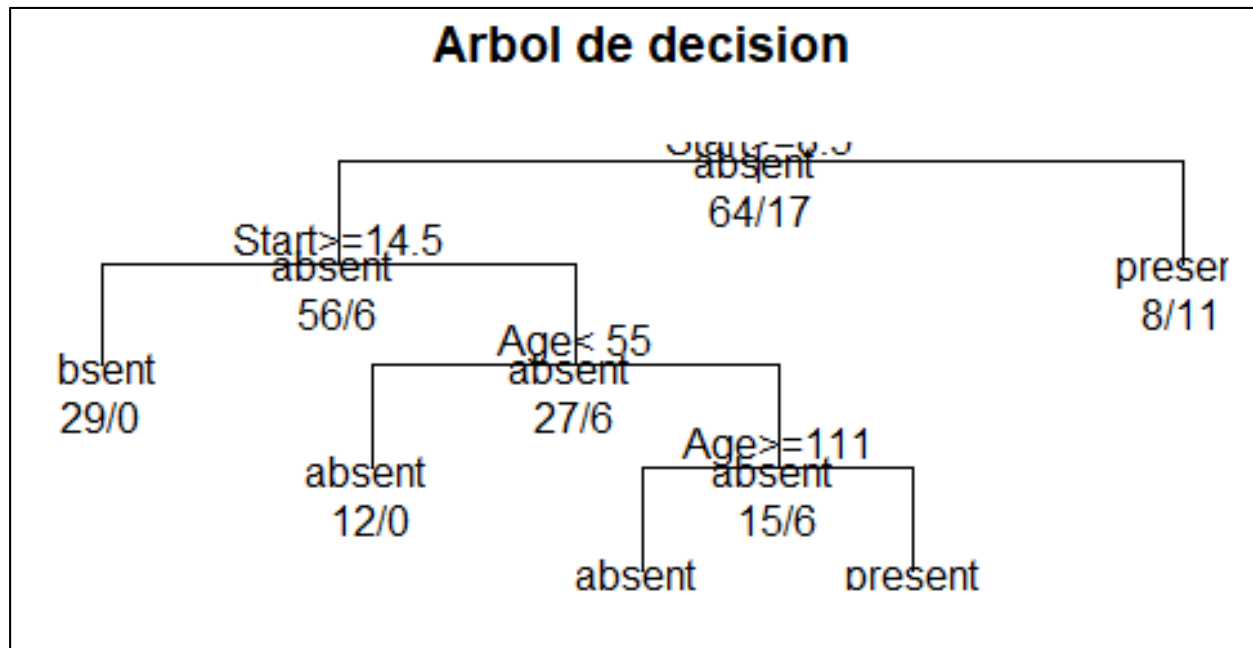
**Nota:** Nos faltan los textos.



# 1. EJEMPLO ARBOLES DE DECISION

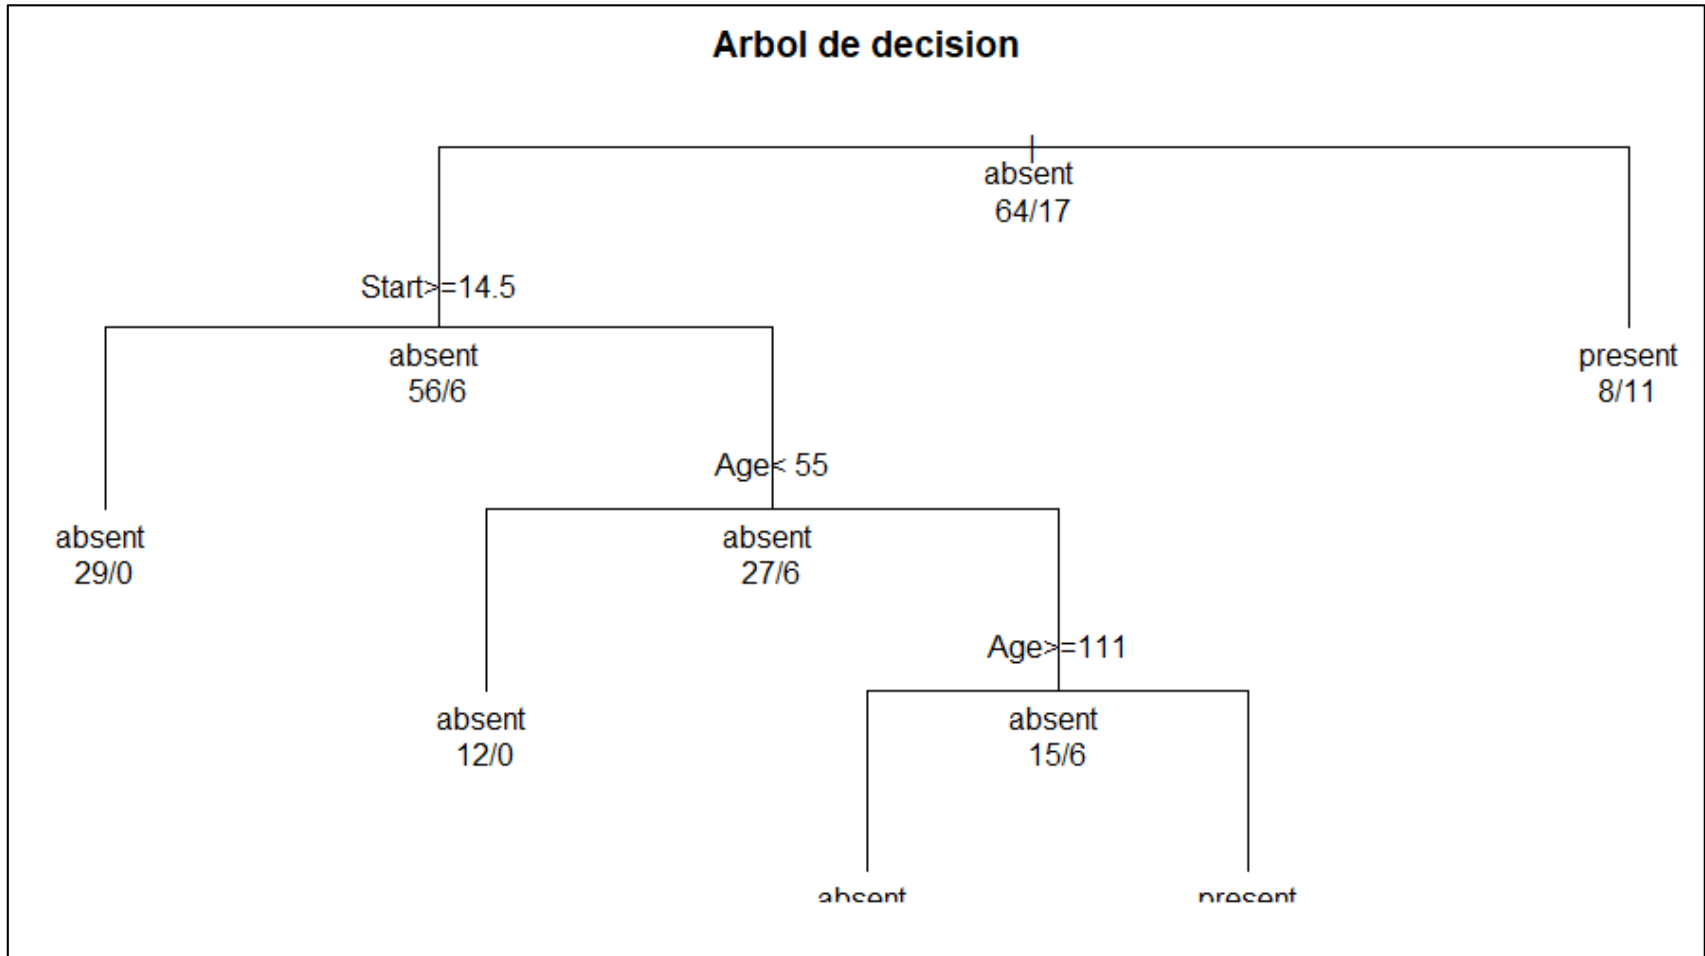
**Paso 6.** Agregamos los textos con la función text. Añade todas las etiquetas al árbol.

```
> text(arbol, use.n=TRUE, all=TRUE)  
> |
```



# 1. EJEMPLO ARBOLES DE DECISION

Paso 7. Para que se vea bien tenemos que darle al zoom.



# 1. EJEMPLO ARBOLES DE DECISION

---

## Explicación

- Vemos el árbol de decisión en función de dónde comienza por ejemplo la columna start
- Si start es  $\geq 14.5$  va por la izquierda indicando que esta ausente la enfermedad.
- Si start  $< 14.5$ , entonces si la edad es  $< 55$ , va por el lado derecho indicando que la enfermedad esta ausente.
- El árbol de decisión está en función de los valores de las columnas. Al final acaban dando resultados de si está presente o ausente la enfermedad, según los datos de las columnas

# 1. EJEMPLO ARBOLES DE DECISION

---

**Paso 8.** Utilizaremos otro gráfico donde se ve mejor el árbol de decisión: `rpart.plot`

Lo instalamos y lo cargamos en memoria

```
> install.packages('rpart.plot')
Installing package into 'C:/Users/eduar/AppData/Local/R/win-library/4.3'
(as 'lib' is unspecified)
probando la URL 'https://cran.rstudio.com/bin/windows/contrib/4.3/rpart.plot_3.1.1.zip'
Content type 'application/zip' length 1035076 bytes (1010 KB)
downloaded 1010 KB

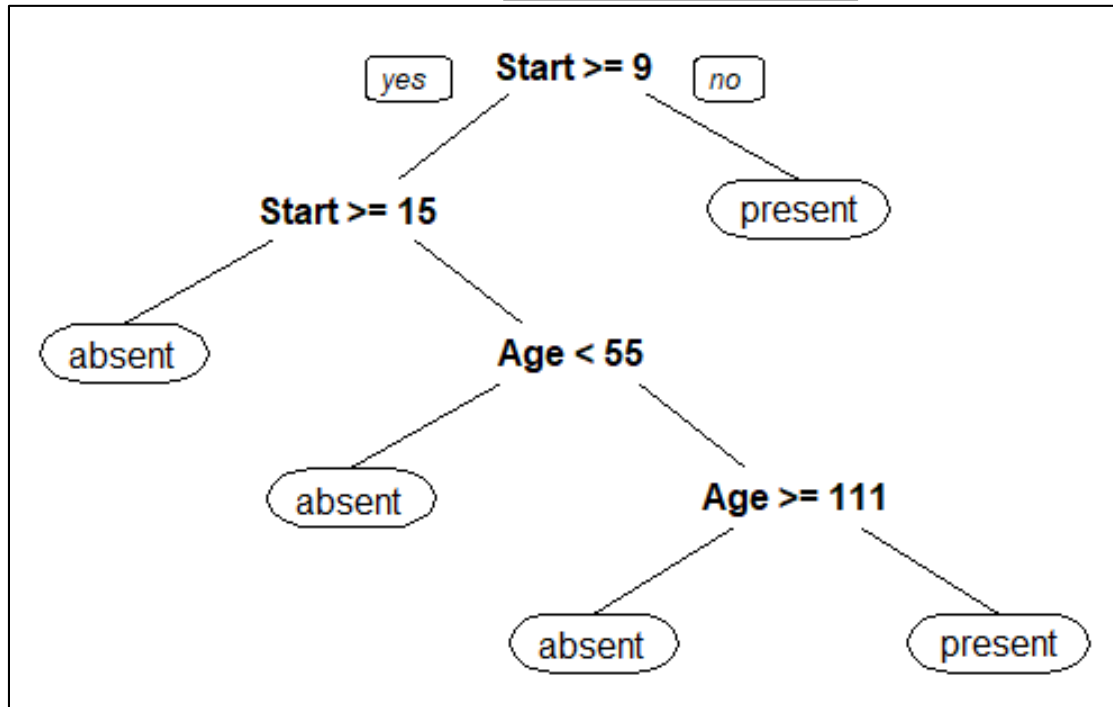
package 'rpart.plot' successfully unpacked and MD5 sums checked

The downloaded binary packages are in
      C:\Users\eduar\AppData\Local\Temp\Rtmpopvs11\downloaded_packages
> library(rpart.plot)
>
```

# 1. EJEMPLO ARBOLES DE DECISION

Paso 9. Visualizamos el árbol de decisión con la función prp.

```
> prp(arbol)
> |
```




En función de la variable start, si es  $\geq 9$ , si es true va por la izquierda indicando que la enfermedad es presente, y si es false va por la derecha. Si  $\text{start} \geq 15$ , si es que si esta ausente de la enfermedad, etc

En función de start y edad se van evalúan las distintas opciones y nos daría el resultado de la predicción kyphosis

## 2. RANDOM FOREST

Random Forest (bosque aleatorio) es una combinación de árboles de decisión donde cada árbol selecciona una clase y luego se combinan las decisiones de cada árbol para seleccionar una clase final ganadora.



Es uno de los algoritmos de aprendizaje de clasificación con mayor precisión

Funciona de forma eficiente con base de datos grandes.

Además, puede manejar cientos de variables de entrada.

## 2. EJEMPLO DE RANDOM FOREST

---

**Paso 1.** Random Forest es un algoritmo de clasificación que combina diferentes árboles hasta encontrar el árbol óptimo. Instalamos el paquete de Random Forest, y lo cargamos en memoria

```
> install.packages('randomForest')
Installing package into 'C:/Users/eduar/AppData/Local/R/win-library/4.3'
(as 'lib' is unspecified)
probando la URL 'https://cran.rstudio.com/bin/windows/contrib/4.3/randomForest_4.7-1.1.zip'
Content type 'application/zip' length 222252 bytes (217 KB)
downloaded 217 KB

package 'randomForest' successfully unpacked and MD5 sums checked

The downloaded binary packages are in
      C:\Users\eduar\AppData\Local\Temp\Rtmpopvs11\downloaded_packages
> library(randomForest)
randomForest 4.7-1.1
Type rfNews() to see new features/changes/bug fixes.
> |
```

## 2. EJEMPLO DE RANDOM FOREST

---

**Paso 2.** Ahora lo que hacemos es crear el modelo. Usamos la función `randomForest` a la que le pasamos la columna `kyphosis`, que es que queremos estimar, y `datos`.

Hacemos el `print` del modelo.

```
> modelo = randomForest(kyphosis ~ . , data=datos)
> print(modelo)

call:
 randomForest(formula = kyphosis ~ . , data = datos)
      Type of random forest: classification
      Number of trees: 500
No. of variables tried at each split: 1

      OOB estimate of  error rate: 23.46%
Confusion matrix:
      absent present class.error
absent      59      5  0.0781250
present     14      3  0.8235294
>
```

Tenemos el modelo de Random Forest para el dataset `kyphosis`

Indica el número de árboles utilizado, el tipo de `randomforest` de clasificación y nos da también la matriz de confusión.



## 2. EJEMPLO DE RANDOM FOREST

Paso 3. Para ver las predicciones que ha realizado este algoritmo de RandomForest, usamos **modelo\$predicted**

```
> modelo$predicted
  1      2      3      4      5      6      7      8      9     10
present absent absent absent absent absent absent absent absent absent
 11     12     13     14     15     16     17     18     19     20
absent  absent absent absent absent absent absent absent absent absent
 21     22     23     24     25     26     27     28     29     30
absent present absent present absent absent absent absent absent absent
 31     32     33     34     35     36     37     38     39     40
absent absent absent absent absent absent absent absent absent absent
 41     42     43     44     45     46     47     48     49     50
absent absent present absent absent absent absent absent absent absent
 51     52     53     54     55     56     57     58     59     60
absent absent absent absent absent absent absent present present absent
 61     62     63     64     65     66     67     68     69     70
absent present present absent absent absent absent absent absent absent
 71     72     73     74     75     76     77     78     79     80
absent absent absent absent absent absent absent absent absent absent
 81
absent
Levels: absent present
> |
```

Nos indica que esta presente para la fila 1, ausente para la fila 2, etc, así hasta las 81 observaciones.

El algoritmo nos da las predicciones para todas las filas en función de los valores de las otras columnas.

### 3. MAQUINAS DE VECTORES DE SOPORTE


---

- Las máquinas de soporte vectorial (SVM) son un conjunto de algoritmos de aprendizaje supervisado para resolver problemas de clasificación y de regresión.
- Dado un conjunto de ejemplos de entrenamiento, podemos etiquetar las clases y entrenar una SVM para construir un modelo que prediga la clase de una nueva muestra.
- Representan los puntos de muestra en el espacio, separando las clases en dos espacios de la forma más amplia posible mediante un hiperplano de separación, denominado vector de soporte

### 3. MAQUINAS DE VECTORES DE SOPORTE

---

- En la siguiente grafico el vector de soporte puede ser la línea roja que separa el grupo de puntos de muestra azules de los verdes.
- Así, una vez que tengamos una nueva muestra, podemos ver si está a la derecha de la raya roja o pertenecer al grupo azul, y si está a la izquierda pertenece al Grupo Verde.



### 3. EJEMPLO DE MAQUINAS DE VECTORES DE SOPORTE

**Paso 1.** Vamos a ver el algoritmo de máquinas de vectores de soporte SVM. Utilizaremos el dataset iris que viene en el paquete ISLR.

```
> library(ISLR)
> datos = iris
> str(datos)
'data.frame': 150 obs. of 5 variables:
 $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ Species : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ..
> |
```

Data	
datos	150 obs. of 5 variables

El dataset tiene 150 filas y 5 columnas: la longitud y el ancho del sépalo, la longitud y el ancho del pétalo, y luego, en función de sus características, la especie que es, que puede ser de tipos: setosa, versicolor y virginica

### 3. EJEMPLO DE MAQUINAS DE VECTORES DE SOPORTE

---

Paso 2. Instalaremos otro paquete para utilizar el SVM o el algoritmo de máquinas de vectores de soporte. Entonces instalamos el paquete e1071.

```
> install.packages('e1071')
Installing package into 'C:/Users/eduar/AppData/Local/R/win-library/4.3'
(as 'lib' is unspecified)
also installing the dependency 'proxy'

probando la URL 'https://cran.rstudio.com/bin/windows/contrib/4.3/proxy_0.4-27.zip'
Content type 'application/zip' length 179932 bytes (175 KB)
downloaded 175 KB

probando la URL 'https://cran.rstudio.com/bin/windows/contrib/4.3/e1071_1.7-14.zip'
Content type 'application/zip' length 664440 bytes (648 KB)
downloaded 648 KB

package 'proxy' successfully unpacked and MD5 sums checked
package 'e1071' successfully unpacked and MD5 sums checked

The downloaded binary packages are in
  C:\Users\eduar\AppData\Local\Temp\Rtmp4YbTsm\downloaded_packages
> library(e1071)
> |
```

# 3. EJEMPLO DE MAQUINAS DE VECTORES DE SOPORTE

**Paso 3.** Para obtener mas información sobre este algoritmo ponemos `help('svm')`, y nos sale la página de ayuda de `rstudio` donde podemos ver el algoritmo y la información de los distintos parámetros que podemos usar. Al final de todo vienen ejemplos de optimización

## Support Vector Machines

### Description

`svm` is used to train a support vector machine. It can be used to carry out general regression and classification (of nu and epsilon-type), as well as density-estimation. A formula interface is provided.

### Usage

```
## S3 method for class 'formula'
svm(formula, data = NULL, ..., subset, na.action =
na.omit, scale = TRUE)
## Default S3 method:
svm(x, y = NULL, scale = TRUE, type = NULL, kernel =
"radial", degree = 3, gamma = if (is.vector(x)) 1 else 1 / ncol(x),
coef0 = 0, cost = 1, nu = 0.5,
class.weights = NULL, cachesize = 40, tolerance = 0.001, epsilon = 0.1,
shrinking = TRUE, cross = 0, probability = FALSE, fitted = TRUE,
..., subset, na.action = na.omit)
```

### Arguments

<code>formula</code>	a symbolic description of the model to be fit.
<code>data</code>	an optional data frame containing the variables in the model. By default the variables are taken from the environment which 'svm' is called from.

### 3. EJEMPLO DE MAQUINAS DE VECTORES DE SOPORTE

---

**Paso 4.** Vamos a construir el modelo de la máquina de vectores de soporte.

```
> modelo = svm(Species ~ . , data=datos)
> predicciones = predict(modelo, datos[1:4])
>
```

Usamos el algoritmo SVM y vamos a predecir en este caso la columna Species a partir de todos los datos del dataset

**Paso 5.** A partir de este modelo vamos a hacer las predicciones. Formulamos una variable predicciones que va a ser el resultado del método Predict al que le vamos a pasar el modelo y las cuatro primeras columnas que contienen las características.

### 3. EJEMPLO DE MAQUINAS DE VECTORES DE SOPORTE

---

Paso 6. Si vemos proyecciones, veremos las predicciones que realiza nuestro modelo para cada una de las filas.

Las primeras filas son setosa

```
> predicciones
  1      2      3      4      5      6
setosa  setosa  setosa  setosa  setosa  setosa
  7      8      9     10     11     12
setosa  setosa  setosa  setosa  setosa  setosa
 13     14     15     16     17     18
setosa  setosa  setosa  setosa  setosa  setosa
 19     20     21     22     23     24
setosa  setosa  setosa  setosa  setosa  setosa
 25     26     27     28     29     30
setosa  setosa  setosa  setosa  setosa  setosa
 31     32     33     34     35     36
setosa  setosa  setosa  setosa  setosa  setosa
 37     38     39     40     41     42
setosa  setosa  setosa  setosa  setosa  setosa
 43     44     45     46     47     48
setosa  setosa  setosa  setosa  setosa  setosa
 49     50     51     52     53     54
setosa  setosa versicolor versicolor versicolor versicolor
 55     56     57     58     59     60
versicolor versicolor versicolor versicolor versicolor versicolor
 61     62     63     64     65     66
versicolor versicolor versicolor versicolor versicolor versicolor
```



### 3. EJEMPLO DE MAQUINAS DE VECTORES DE SOPORTE

**Paso 7.** Si queremos visualizar el modelo de una forma más clara, podemos visualizar los datos junto con las predicciones. Construimos una tabla que va a ser un data.frame con los datos y las predicciones.

```
> tabla
```

	Sepal.Length	Sepal.width	Petal.Length	Petal.width	Species	predicciones
1	5.1	3.5	1.4	0.2	setosa	setosa
2	4.9	3.0	1.4	0.2	setosa	setosa
3	4.7	3.2	1.3	0.2	setosa	setosa
4	4.6	3.1	1.5	0.2	setosa	setosa
5	5.0	3.6	1.4	0.2	setosa	setosa
6	5.4	3.9	1.7	0.4	setosa	setosa
7	4.6	3.4	1.4	0.3	setosa	setosa
8	5.0	3.4	1.5	0.2	setosa	setosa
9	4.4	2.9	1.4	0.2	setosa	setosa
10	4.9	3.1	1.5	0.1	setosa	setosa
11	5.4	3.7	1.5	0.2	setosa	setosa
12	4.8	3.4	1.6	0.2	setosa	setosa
13	4.8	3.0	1.4	0.1	setosa	setosa
14	4.3	3.0	1.1	0.1	setosa	setosa
15	5.8	4.0	1.2	0.2	setosa	setosa
16	5.7	4.4	1.5	0.4	setosa	setosa
17	5.4	3.9	1.3	0.4	setosa	setosa
18	5.1	3.5	1.4	0.3	setosa	setosa
19	5.7	3.8	1.7	0.3	setosa	setosa
20	5.1	3.8	1.5	0.3	setosa	setosa
21	5.4	3.4	1.7	0.2	setosa	setosa
22	5.1	3.7	1.5	0.4	setosa	setosa
23	4.6	3.6	1.0	0.2	setosa	setosa

Vemos los valores de cada una de las columnas de especies y nuestras predicciones.

Las predicciones casi siempre aciertan con la especie. El modelo svm funciona muy bien para este dataset


## 4. ALGORITMO DE K-MEDIAS

---

- El algoritmo de medias es un algoritmo de aprendizaje no supervisado para resolver el problema de la clusterización o la formación de grupos
- Tiene como objetivo la partición de un conjunto de "n" observaciones en "k" grupos, en la que cada observación pertenece al grupo cuyo valor medio es más cercano.
- Es un método utilizado en la minería de datos.

## 4. ALGORITMO DE K-MEDIAS

- Diagrama de izquierda derecha que muestra las distintas fases por las que va pasando hasta que al final cada observación pertenece a un grupo concreto.
- En este caso K es igual a tres.
- Todas las formaciones están dentro o agrupadas dentro tres grupos.



## 4. EJEMPLO ALGORITMO DE K-MEDIAS

---

**Paso 1.** Vamos a ver un ejemplo del algoritmo de k-medias es un algoritmo de aprendizaje no supervisado

Primero cargaremos el paquete ISLR y utilizaremos el dataset irish. Si hacemos un dataset de datos, vemos que tiene 150 observaciones con 5 variables: longitud y ancho de los sépalos, longitud y ancho de los pétalos y según eso vamos a intentar identificar cuál es la especie.

```
> library(ISLR)
> datos = iris
> str(datos)
'data.frame': 150 obs. of 5 variables:
 $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ species : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...
> |
```

## 4. EJEMPLO ALGORITMO DE K-MEDIAS

---

**Paso 2.** Vamos a hacer un gráfico para ver cómo se agrupan las especies en este caso por colores.

Cargaremos la librería ggplot2

```
> install.packages("ggplot2")
Installing package into 'C:/Users/eduar/AppData/Local/R/win-library/4.3'
(as 'lib' is unspecified)
probando la URL 'https://cran.rstudio.com/bin/windows/contrib/4.3/ggplot2_3.4.4.zip'
Content type 'application/zip' length 4299762 bytes (4.1 MB)
downloaded 4.1 MB

package 'ggplot2' successfully unpacked and MD5 sums checked

The downloaded binary packages are in
      C:\Users\eduar\AppData\Local\Temp\RtmpoLYcWP\downloaded_packages
> library(ggplot2)
> |
```

## 4. EJEMPLO ALGORITMO DE K-MEDIAS

---

**Paso 3.** Crearemos un gráfico mediante un ggplot.


```
> grafico = ggplot(datos, aes(Petal.Length, Petal.Width, color=Species))  
> grafico = grafico + geom_point(size=5)  
> print(grafico)  
> |
```

Le pasaremos los datos: en el eje x  $\rightarrow$  Petal.Length, en el eje y  $\rightarrow$  Petal.Width y que ponga los colores según las especies, así podremos ver la agrupación entre especies.

Y por último, le decimos que añada el grafico tipo `geom_point`, donde le vamos a poner un tamaño de 5.

## 4. EJEMPLO ALGORITMO DE K-MEDIAS

### Paso 4. Visualizamos el gráfico



En función de estos dos atributos Petal.Length y Petal.Width vemos que los 3 grupos de especies han quedado bastante bien agrupados:

color rojo → setosa

Color verde → versicolor

Color azul → virginica

## 4. EJEMPLO ALGORITMO DE K-MEDIAS

---

**Paso 5.** Vamos a crear el modelo o el algoritmo de k-medias. Primero ponemos la semilla y creamos una variable, que son los conjuntos de especies mediante kmeans

```
> set.seed(90)  
> conjuntos = kmeans(datos[,1:4],3, nstart=20)
```

En este caso le pasamos las primeras 4 columnas de datos. Como hay 3 conjuntos de especies/colores ponemos un 3 y por último nstart lo ponemos a 20



## 4. EJEMPLO ALGORITMO DE K-MEDIAS

**Paso 6.** Si hacemos un print de los conjuntos para ver la información que ha generado el algoritmo de k-medias, vemos que he agrupado en tres clusters o conjuntos que tienen un tamaño de 38, 50 y 62 elementos

[illegible]

Aquí  
tenemos los  
valores que  
nos saca

## 4. EJEMPLO ALGORITMO DE K-MEDIAS

---

**Paso 7.** Si queremos ver esto en una tabla donde podamos ver cuántas especies hay en cada conjunto:

```
> table(conjuntos$cluster, datos$Species)

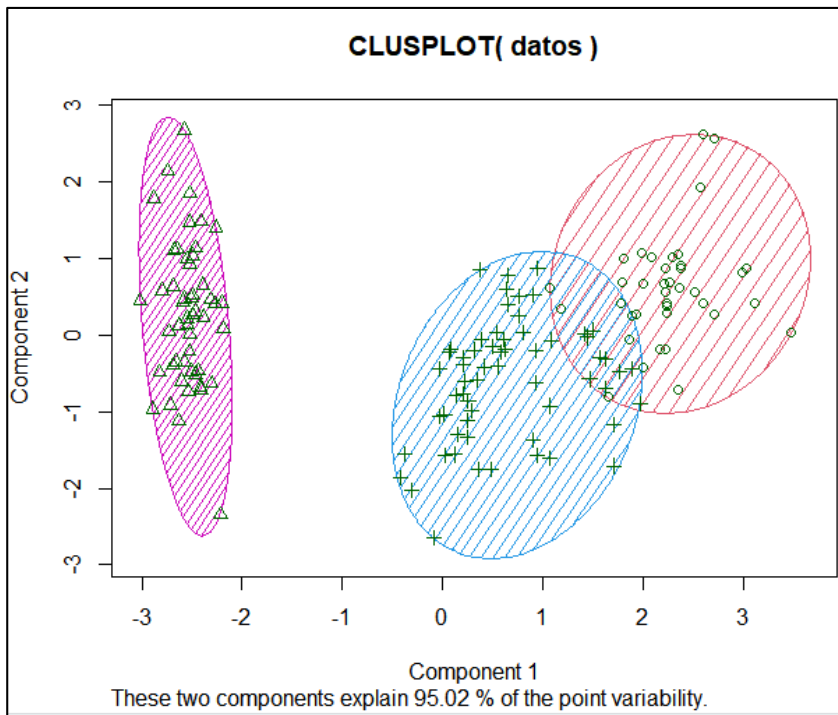
      setosa versicolor virginica
1         0          2         36
2        50          0          0
3         0         48         14
> |
```

Vemos los datos para cada uno de los clusters o conjuntos. En el primer clúster aparece 0 (setosa), 2 (versicolor) y 36(virginica). En el segundo aparece 50, 0 y 0, y en el tercero 0, 48 y 14.

## 4. EJEMPLO ALGORITMO DE K-MEDIAS

**Paso 8.** También podemos realizar otro gráfico para ver los conjuntos representados por círculos. Cargamos el paquete cluster y lo vamos a utilizar mediante el clusplot

```
> library(cluster)
> clusplot(datos, conjuntos$cluster, color=TRUE, shade=TRUE, labels=0, lines=0)
> |
```



Genera otro tipo de gráfico donde podemos agrupar la información que ha generado el algoritmo de k-medias, separándolo por círculos y colores.

## 4. EJEMPLO ALGORITMO DE K-MEDIAS

**Paso 9.** Si queremos más información del algoritmo de kmedias, simplemente tendríamos que ejecutar `help` y el nombre del algoritmo. Podemos ver los distintos parámetros que hay, y al final siempre viene un ejemplo que podemos utilizar.

```
> help('kmeans')  
> |
```

### K-Means Clustering

#### Description

Perform k-means clustering on a data matrix.

#### Usage

```
kmeans(x, centers, iter.max = 10, nstart = 1,  
       algorithm = c("Hartigan-Wong", "Lloyd", "Forgy",  
                     "MacQueen"), trace = FALSE)  
## S3 method for class 'kmeans'  
fitted(object, method = c("centers", "classes"), ...)
```

#### Arguments

<code>x</code>	numeric matrix of data, or an object that can be coerced to such a matrix (such as a numeric vector or a data frame with all numeric columns).
<code>centers</code>	either the number of clusters, say $k$ , or a set of initial (distinct) cluster centres. If a number, a random set of (distinct) rows in <code>x</code> is chosen as the initial centres.
<code>iter.max</code>	the maximum number of iterations allowed.
<code>nstart</code>	if <code>centers</code> is a number, how many random sets should be chosen?
<code>algorithm</code>	character; may be abbreviated. Note that "Lloyd" and "Forgy" are alternative